TRƯỜNG ĐẠI HỌC SÀI GÒN — KHOA TOÁN- ỨNG DỤNG
BỘ MÔN KHOA HỌC DỮ LIỆU

PROPOSAL ĐỀ TÀI CUỐI KỲ

ĐỀ TÀI: TỰ ĐỘNG SINH CHÚ THÍCH HÌNH ẢNH SỬ DỤNG KIẾN TRÚC ENCODER-DECODER VÀ CƠ CHẾ ATTENTION TRÊN PYTORCH VÀ CHUYỂN NGỮ ANH–VIỆT BẰNG HỌC SÂU

1. THÔNG TIN NHÓM & PHÂN CÔNG NHIỆM VỤ

- **Tên đề tài tiếng Việt:** Tự động sinh chú thích hình ảnh bằng tiếng Anh và chuyển ngữ sang tiếng Việt bằng học sâu trên PyTorch.
- **Tên đề tài tiếng Anh:** Image Captioning and English-to-Vietnamese Translation with Deep Learning.

STT	Họ và tên	MSSV	Vai trò	Nhiệm vụ chính phụ trách
1	Nguyễn Trương Cao Sơn	3123580040	**Nhóm trưởng**	Thiết kế kiến trúc hệ thống; triển khai mô hình mở rộng ViT-B/16 + Transformer Decoder; tổ chức thí nghiệm đối chứng và tổng hợp báo cáo.
2	Đặng Thanh Phương	3123580036	Thành viên	Thu thập, kiểm tra và tiền xử lý Flickr30k; xây dựng Dataset/DataLoader bằng PyTorch; xây dựng từ điển từ vựng và triển khai mô hình cơ sở CNN-LSTM.
3	Phạm Trung Hiếu	3123580014	Thành viên	Xây dựng mô-đun đánh giá BLEU, METEOR, ROUGE-L, CIDEr; khảo sát mô hình dịch Anh–Việt; phát triển demo Streamlit/Gradio và trực quan hóa Attention.

2. GIỚI THIỆU BÀI TOÁN & CÂU HỎI NGHIÊN CỨU (RQs)

2.1. Bối cảnh và ý nghĩa thực tiễn: Sinh chú thích hình ảnh là bài toán kết hợp giữa thị giác máy tính và xử lý ngôn ngữ tự nhiên. Mô hình nhận một hình ảnh làm đầu vào và tạo ra câu mô tả bằng ngôn ngữ tự nhiên, thể hiện những đối tượng, hoạt động và bối cảnh chính trong ảnh.

Bài toán có một số ứng dụng thực tiễn như hỗ trợ người khiếm thị tiếp cận thông tin hình ảnh thông qua mô tả bằng âm thanh; hỗ trợ lập chỉ mục và tìm kiếm ảnh theo nội dung; và hỗ trợ tạo mô tả cho hình ảnh trên các nền tảng số.

So với phân loại ảnh, bài toán này không chỉ yêu cầu nhận diện đối tượng mà còn cần xác định hoạt động và mối quan hệ giữa các đối tượng, sau đó diễn đạt thông tin thành một câu có nghĩa. Vì vậy, mô hình cần kết hợp đặc trưng thị giác với khả năng sinh chuỗi ngôn ngữ.

2.2. Mục tiêu nghiên cứu: Nhóm xây dựng quy trình gồm hai giai đoạn. Giai đoạn thứ nhất sử dụng các mô hình học sâu triển khai bằng PyTorch để sinh chú thích tiếng Anh từ ảnh trên tập Flickr30k, với mô hình CNN-LSTM làm đường cơ sở và các mô hình có cơ chế chú ý hoặc bộ mã hóa thị giác Transformer để so

sánh. Giai đoạn thứ hai chuyển câu tiếng Anh do mô hình tạo ra sang tiếng Việt bằng một mô hình dịch máy tiền huấn luyện. Nhóm đánh giá riêng chất lượng chú thích tiếng Anh và chất lượng bản dịch tiếng Việt, đồng thời xây dựng bản demo web để minh họa quy trình.

2.3. Câu hỏi nghiên cứu: Để đảm bảo tính khoa học và có thể kiểm chứng định lượng bằng thực nghiệm, nhóm đặt ra 3 Câu hỏi nghiên cứu trọng tâm sau:

- RQ1 (Về cơ chế chú ý): Khi giữ nguyên bộ mã hóa ResNet-50 và bộ giải mã LSTM, việc bổ sung cơ chế chú ý không gian Bahdanau có cải thiện chất lượng chú thích tiếng Anh so với mô hình không sử dụng Attention hay không? Mức cải thiện được đo bằng BLEU-1 đến BLEU-4, METEOR và CIDEr.
- RQ2 (Về cấu hình Encoder-Decoder): Trong cùng điều kiện dữ liệu và đánh giá, cấu hình ResNet-50 kết hợp LSTM có Attention và cấu hình ViT-B/16 kết hợp Transformer Decoder khác nhau như thế nào về chất lượng chú thích tiếng Anh và chi phí tính toán? Câu hỏi này so sánh hai cấu hình tổng thể, không tách riêng tác động của từng thành phần kiến trúc.
- RQ3 (Về chiến lược giải mã): Với cùng một mô hình đã huấn luyện, độ rộng Beam Search $k \in \{1, 3, 5, 7\}$ ảnh hưởng như thế nào đến chất lượng câu được sinh ra (BLEU, CIDEr) và thời gian suy luận trên mỗi ảnh?

3. MÔ TẢ TẬP DỮ LIỆU

3.1. Nguồn gốc và đường dẫn dữ liệu: Nhóm lựa chọn Flickr30k làm tập dữ liệu chính cho bài toán sinh chú thích hình ảnh.

- Tên tập dữ liệu: Flickr30k gồm ảnh chụp trong các bối cảnh đời thực và năm câu chú thích tiếng Anh do con người viết cho mỗi ảnh. Theo thông tin từ trang dữ liệu gốc, nhóm phát hành không sở hữu bản quyền các ảnh; ảnh được cung cấp cho mục đích nghiên cứu và giáo dục phi thương mại. Nhóm sẽ tuân thủ điều khoản sử dụng của Flickr và điều kiện truy cập của bộ dữ liệu.
- Nguồn dữ liệu: https://huggingface.co/datasets/nlphuji/flickr30k. Trang dữ liệu gốc: https://shannon.cs.illinois.edu/DenotationGraph/data/. Trước khi tải, nhóm sẽ kiểm tra cấu trúc tệp, phiên bản chú thích, cách chia tập và điều khoản sử dụng ảnh.
- Quy mô dữ liệu: Flickr30k có 31.783 ảnh, mỗi ảnh đi kèm năm chú thích tiếng Anh, tương đương 158.915 câu mô tả. Dung lượng tải xuống thực tế phụ thuộc phiên bản và cách lưu trữ ảnh.
- Tính khả thi về tài nguyên: Quy mô Flickr30k phù hợp với đồ án sinh viên nếu sử dụng các bộ mã hóa đã được huấn luyện trước, đóng băng trọng số ở giai đoạn đầu hoặc lưu đặc trưng ảnh để tái sử dụng. Nhóm sẽ ưu tiên hoàn thành mô hình cơ sở và mô hình Attention trước; mô hình ViT được triển khai ở mức mở rộng, với batch size và phạm vi tinh chỉnh phù hợp với GPU hiện có.

3.2. Đặc điểm đầu vào & đầu ra bài toán:

- **Đầu vào:** Ảnh màu RGB với kích thước ban đầu khác nhau. Ảnh được đưa về kích thước 224 × 224 pixel và chuẩn hóa theo trung bình, độ lệch chuẩn của ImageNet (mean = [0.485, 0.456, 0.406], std = [0.229, 0.224, 0.225]).
- **Đầu ra trung gian – chú thích tiếng Anh:** Chuỗi từ $Y_EN = (y_1, y_2, \ldots, y_T)$ mô tả nội dung ảnh, được mô hình sinh tuần tự. Chuỗi bắt đầu bằng token <start> và kết thúc bằng token <end>.
- **Đầu ra cuối cùng – chú thích tiếng Việt:** Câu tiếng Anh được chuyển sang tiếng Việt bằng mô hình dịch máy Anh–Việt đã tiền huấn luyện. Bản dịch hướng đến việc giữ đúng nội dung chính của câu gốc, sử dụng từ ngữ phù hợp và diễn đạt tự nhiên trong tiếng Việt.

4. PHƯƠNG PHÁP DỰ KIẾN TRIỂN KHAI BẰNG PYTORCH

4.1. Quy trình tiền xử lý dữ liệu: Mô hình sinh chú thích được xây dựng và huấn luyện bằng PyTorch. Quy trình được chia thành các mô-đun để thuận tiện cho việc thử nghiệm và đánh giá.

- Tiền xử lý ảnh: Trong quá trình huấn luyện, ảnh được resize về 256 × 256 pixel, sau đó cắt ngẫu nhiên về 224 × 224 pixel và có thể áp dụng lật ngang ngẫu nhiên. Với tập validation và test, nhóm dùng Center Crop để bảo đảm phép biến đổi ổn định.
- Tiền xử lý văn bản: Chuyển câu về chữ thường, chuẩn hóa khoảng trắng và dấu câu, sau đó tách từ. Từ điển được xây dựng chỉ từ chú thích của tập train, với ngưỡng tần số tối thiểu dự kiến min_freq = 5; kích thước từ điển sẽ được xác định sau khi thống kê dữ liệu. Bổ sung các token đặc biệt như <pad>, <unk>, <start> và <end>; dùng padding để đưa các chuỗi trong cùng batch về độ dài thống nhất.

4.2. Các kiến trúc học sâu dự kiến: Nhóm triển khai mô hình cơ sở và hai cấu hình mở rộng để so sánh. Các thí nghiệm sẽ sử dụng cùng tập dữ liệu và quy trình đánh giá nhằm bảo đảm khả năng đối chiếu.

- **Mô hình 1 – Baseline (CNN + LSTM):** Mô hình tham khảo kiến trúc Show and Tell (Vinyals et al., 2015). Encoder sử dụng ResNet-50 tiền huấn luyện và bỏ tầng phân loại cuối để trích xuất vector đặc trưng toàn cục 2.048 chiều. Vector này được chiếu về không gian embedding 512 chiều và dùng để khởi tạo trạng thái của bộ giải mã LSTM một tầng. LSTM sinh từng từ dựa trên trạng thái hiện tại và từ đã được cung cấp ở bước trước.
- **Mô hình 2 – ResNet-50 + Bahdanau Attention + LSTM:** Mô hình tham khảo hướng tiếp cận Show, Attend and Tell (Xu et al., 2015). Với ảnh đầu vào 224 × 224 pixel, đầu ra mặc định của tầng cuối ResNet-50 có kích thước 7 × 7 × 2.048, tương ứng 49 vị trí đặc trưng không gian. Tại mỗi bước sinh từ, cơ chế chú ý Bahdanau tính trọng số cho các vị trí này và kết hợp chúng thành vector ngữ cảnh để bộ giải mã LSTM dự đoán từ tiếp theo.
- **Mô hình 3 – ViT-B/16 + Transformer Decoder:** Đây là mô hình mở rộng nếu tài nguyên cho phép. Encoder sử dụng Vision Transformer ViT-Base/16 tiền huấn luyện. Với ảnh 224 × 224 pixel, ảnh được chia thành 196 patch kích thước 16 × 16 và mã hóa thành chuỗi đặc trưng thị giác. Transformer Decoder sử dụng cơ chế tự chú ý có mặt nạ và chú ý chéo để kết hợp thông tin từ chuỗi từ với đặc trưng ảnh. Nhóm không xem cấu hình này là mô hình SOTA, mà dùng để khảo sát một kiến trúc dựa trên Transformer trong phạm vi đồ án.

4.3. Mô-đun chuyển ngữ Anh–Việt: Sau khi mô hình PyTorch sinh chú thích tiếng Anh, câu này được đưa vào một mô hình dịch máy tiền huấn luyện cho cặp ngôn ngữ Anh–Việt. Nhóm dự kiến khảo sát một checkpoint như VietAI/envit5-translation hoặc mô hình tương đương, sau đó lựa chọn dựa trên khả năng dịch đúng chiều ngôn ngữ, giấy phép, kích thước và tốc độ suy luận trên tài nguyên hiện có. Flickr30k chỉ cung cấp chú thích tiếng Anh, không có chú thích tiếng Việt đi kèm; vì vậy, nhóm sẽ đánh giá bản dịch bằng rubric do nhóm xây dựng hoặc bổ sung một tập tham chiếu tiếng Việt được người biết song ngữ hiệu đính. Không mặc định xem bản dịch tự động là đáp án chuẩn.

5. THIẾT KẾ THỰC NGHIỆM & KẾ HOẠCH ABLATION STUDIES

5.1. Phân chia dữ liệu: Nhóm sử dụng file phân chia theo giao thức Karpathy đi kèm phiên bản dữ liệu đã chọn và tách theo ảnh để tránh trường hợp chú thích của cùng một ảnh xuất hiện ở nhiều tập. Cấu hình dự kiến gồm 29.769 ảnh train, 1.014 ảnh validation và 1.000 ảnh test; nhóm sẽ xác nhận số lượng thực tế bằng cách thống kê trường split trong tệp annotation trước khi huấn luyện. Tập test chỉ được dùng ở bước đánh giá cuối cùng.

5.2. Các chỉ số đánh giá: Chất lượng chú thích tiếng Anh được so sánh với năm câu tham chiếu của mỗi ảnh bằng các chỉ số thường dùng trong bài toán sinh chú thích:

- BLEU-1 đến BLEU-4: Đo mức độ trùng khớp của các cụm từ liên tiếp có độ dài từ một đến bốn giữa câu được sinh và các câu tham chiếu, có xét đến độ dài câu.
- METEOR: So sánh mức độ tương đồng từ vựng giữa câu dự đoán và câu tham chiếu, có xét đến một số dạng biến thể từ và từ đồng nghĩa.
- ROUGE-L: Dựa trên độ dài dãy con chung dài nhất giữa câu dự đoán và câu tham chiếu.

- CIDEr: Đánh giá mức độ phù hợp của chú thích dựa trên các n-gram và trọng số TF-IDF, chú trọng những cụm từ có tính phân biệt trong tập tham chiếu.
- Đánh giá bản dịch tiếng Việt: Do Flickr30k không có câu tham chiếu tiếng Việt, nhóm không tính BLEU-vi nếu chưa xây dựng được tập tham chiếu tương ứng. Trước mắt, nhóm đánh giá thủ công trên 100 ảnh được chọn cố định từ tập test theo thang điểm 1–5 ở ba tiêu chí: (1) bảo toàn nội dung so với chú thích tiếng Anh và ảnh gốc; (2) tự nhiên, mạch lạc về ngữ pháp; (3) lựa chọn từ ngữ phù hợp với ngữ cảnh. Nếu có đủ người hiệu đính, nhóm sẽ bổ sung câu tham chiếu tiếng Việt để tính thêm chỉ số tự động.

5.3. Chiến lược huấn luyện và tối ưu: Mô hình sinh chú thích được huấn luyện bằng Cross-Entropy Loss trên các token mục tiêu; vị trí <pad> được bỏ qua thông qua ignore_index. Nhóm sử dụng Teacher Forcing trong huấn luyện, bộ tối ưu Adam với learning rate khởi đầu 4×10^{-4}, Gradient Clipping với max_norm = 5 và Early Stopping dựa trên loss của tập validation (patience dự kiến 5 epoch). Siêu tham số sẽ được điều chỉnh trên tập validation; tập test không tham gia lựa chọn mô hình.

5.4. Kế hoạch Ablation Study: Nhóm thiết kế các thí nghiệm đối chứng dưới đây. Mỗi thí nghiệm chỉ thay đổi yếu tố đang khảo sát, đồng thời giữ cố định các điều kiện còn lại trong khả năng thực hiện:

Mã TN	Mục tiêu kiểm chứng	Cấu hình so sánh đối chứng	Câu hỏi trả lời
Ablation 1	Ảnh hưởng của cơ chế chú ý	ResNet-50 + LSTM không Attention so với ResNet-50 + Bahdanau Attention + LSTM; giữ nguyên dữ liệu và cấu hình huấn luyện.	RQ1
Ablation 2	So sánh hai cấu hình Encoder-Decoder	ResNet-50 + Bahdanau Attention + LSTM so với ViT-B/16 + Transformer Decoder; đối chiếu chất lượng caption và chi phí tính toán.	RQ2
Ablation 3	Ảnh hưởng của chiến lược giải mã	Trên cùng checkpoint, so sánh Greedy Search (k = 1) với Beam Search (k = 3, 5, 7); đo BLEU/CIDEr và thời gian suy luận.	RQ3
Ablation 4	Ảnh hưởng của việc tinh chỉnh Encoder	So sánh đóng băng toàn bộ Encoder với tinh chỉnh một phần các tầng cuối; dùng learning rate nhỏ hơn cho Encoder. Thực hiện nếu đủ tài nguyên.	Bổ sung

6. KẾT QUẢ DỰ KIẾN & SẢN PHẨM ỨNG DỤNG

6.1. Kết quả định lượng dự kiến: Nhóm kỳ vọng mô hình có cơ chế chú ý và cấu hình ViT có thể cải thiện một số chỉ số so với mô hình cơ sở. Đây là giả thuyết cần kiểm chứng; mức cải thiện và sự khác biệt về thời gian suy luận sẽ được xác định từ kết quả thực nghiệm.

6.2. Phân tích định tính và trực quan hóa: Nhóm dự kiến biểu diễn trọng số Attention trên các vùng ảnh tại từng bước sinh từ để quan sát khu vực được mô hình chú ý. Các bản đồ này được dùng để minh họa hành vi của mô hình, không được xem là bằng chứng duy nhất chứng minh mô hình đã hiểu hoặc suy luận đúng về ảnh.

6.3. Sản phẩm ứng dụng: Nhóm xây dựng bản demo bằng Streamlit hoặc Gradio. Người dùng tải ảnh lên, hệ thống tạo chú thích tiếng Anh rồi chuyển sang tiếng Việt. Giao diện hiển thị ảnh đầu vào, câu tiếng Anh, câu tiếng Việt và bản đồ Attention đối với mô hình có hỗ trợ. Người dùng có thể chọn độ rộng Beam Search (k = 1, 3 hoặc 5) để quan sát sự thay đổi về câu sinh ra và thời gian xử lý.

7. KẾ HOẠCH THỰC HIỆN & TIẾN ĐỘ DỰ KIẾN

Nhóm dự kiến thực hiện đề tài trong 5 tuần. Trình tự công việc được sắp xếp theo mức độ ưu tiên: hoàn thành mô hình cơ sở và mô hình Attention trước, sau đó triển khai mô hình ViT và các thí nghiệm mở rộng khi tài nguyên cho phép.

Thời gian	Công việc chính	Sản phẩm bàn giao	Thành viên phụ trách
Tuần 1	Hoàn thiện Proposal; khảo sát tài liệu; tải và kiểm tra Flickr30k; xây dựng Dataset và DataLoader.	Proposal PDF; script nạp và kiểm tra dữ liệu.	Cả nhóm
Tuần 2	Triển khai mô hình cơ sở CNN-LSTM bằng PyTorch; huấn luyện thử và ghi nhận chỉ số trên validation.	Mã nguồn baseline_cnn_lstm.py; log huấn luyện.	Đặng Thanh Phương
Tuần 3	Triển khai Bahdanau Attention; xây dựng mô hình ViT mở rộng nếu tài nguyên cho phép; hoàn thiện mô-đun đánh giá.	Mã nguồn attention_model.py; mô hình mở rộng; metrics.py.	Nguyễn Trương Cao Sơn; Phạm Trung Hiếu
Tuần 4	Thực hiện các thí nghiệm đối chứng A1–A4 theo mức độ ưu tiên; tinh chỉnh siêu tham số trên validation.	ablation_results.csv; biểu đồ loss và các chỉ số đánh giá.	Sơn, Hiếu
Tuần 5	Tích hợp mô-đun dịch Anh–Việt; xây dựng demo; hoàn thiện báo cáo và slide thuyết trình.	Ứng dụng app.py; báo cáo cuối kỳ; video demo.	Phạm Trung Hiếu; cả nhóm

GitHub Repository dự kiến: https://github.com/nguyentruongcaoson/Image-Captioning-PyTorch-DeepLearning

8. TÀI LIỆU THAM KHẢO CHÍNH

[1] O. Vinyals, A. Toshev, S. Bengio, and D. Erhan, 'Show and Tell: A Neural Image Caption Generator,' in Proceedings of CVPR, 2015, pp. 3156–3164.

[2] K. Xu, J. Ba, R. Kiros, K. Cho, A. Courville, R. Salakhutdinov, R. Zemel, and Y. Bengio, 'Show, Attend and Tell: Neural Image Caption Generation with Visual Attention,' in Proceedings of ICML, 2015, pp. 2048–2057.

[3] A. Vaswani et al., 'Attention Is All You Need,' in Advances in Neural Information Processing Systems, 2017, pp. 5998–6008.

[4] A. Dosovitskiy et al., 'An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale,' in International Conference on Learning Representations, 2021.

[5] M. Hodosh, P. Young, and J. Hockenmaier, 'Framing Image Description as a Ranking Task: Data, Models and Evaluation Metrics,' Journal of Artificial Intelligence Research, vol. 47, pp. 853–899, 2013.

[6] M. Stefanini, M. Cornia, L. Baraldi, S. Cascianelli, G. Fiameni, and R. Cucchiara, 'From Show to Tell: A Survey on Deep Learning-Based Image Captioning,' IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 1, pp. 539–559, 2023.

[7] P. Young, A. Lai, M. Hodosh, and J. Hockenmaier, 'From Image Descriptions to Visual Denotations: New Similarity Metrics for Semantic Inference over Event Descriptions,' Transactions of the Association for Computational Linguistics, vol. 2, pp. 67–78, 2014. (Nguồn giới thiệu Flickr30k: https://shannon.cs.illinois.edu/DenotationGraph/data/).

[8] A. Karpathy and L. Fei-Fei, 'Deep Visual-Semantic Alignments for Generating Image Descriptions,' in Proceedings of CVPR, 2015, pp. 3128–3137.

[9] VietAI, 'envit5-translation,' Hugging Face Model Card, https://huggingface.co/VietAI/envit5-translation (truy cập ngày 03/11/2026).

[10] K. He, X. Zhang, S. Ren, and J. Sun, 'Deep Residual Learning for Image Recognition,' in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.